

Nutzenmesskonzept

Zweck dieses Dokuments
Dieses Dokument beschreibt das Nutzenmesskonzept für die Umstellung der Kundenselektion in Direktwerbeaktionen vom bisherigen Affinitäts-Scoring auf ein kausales Uplift-Modell.

Begriffsklärung
Nutzen = Brutto, vor Handlungsfeld-Kosten, unter Berücksichtigung der unmittelbar dem Use Case zuzuordnenden Kosten (z. B. Versand-/Beauftragungskosten). **Mehrwert** = Nutzen abzüglich der dem Handlungsfeld zuzuordnenden Kosten. Der in Abschnitt 1.2 eingeführte **Nutzenhebel U** ist die physikalische Messgröße (zusätzliche Abschlüsse).

1 Nutzenmesskonzept

1.1 Use Case-Definition

1.1.1 Wirkhebel und Ziele

Bisheriges Vorgehen (Baseline): Affinitäts-Score. Der Affinitäts-Score schätzt die Wahrscheinlichkeit $P(\text{Abschluss} = 1 \mid X)$, dass ein Kunde einen Abschluss tätigt — *unabhängig davon, ob er beworben wurde oder nicht*. Kunden mit hohem Affinitäts-Score hätten das gewünschte Verhalten häufig *ohne hin* gezeigt; sie zu bewerben verursacht Kosten ohne kausalen Zusatznutzen. Im Extremfall werden Kunden beworben, die durch die Maßnahme sogar negativ reagieren („Sleeping Dogs“).

Neues Vorgehen: Kausales Uplift Modeling. Das kausale Modell schätzt den Conditional Average Treatment Effect (CATE):

$$\tau(x) = E[Y(1) - Y(0) \mid X = x]$$

Dabei ist $Y(1)$ das potenzielle Ergebnis unter Treatment, $Y(0)$ das unter Kontrolle. Der CATE gibt an, um wie viel sich die Abschlusswahrscheinlichkeit *kausal durch die Bewerbung* ändert — den reinen Uplift.

Wirkhebel: Bei fest vorgegebener Kampagnengröße werden gezielt die Kunden mit dem höchsten inkrementellen Effekt beworben statt jener mit der höchsten Grundwahrscheinlichkeit. **Ziel:** Mehr kausal ausgelöste Abschlüsse pro Kampagne bei gleichem Mitteleinsatz.




Abb. 1: Kundentypen-Quadranten. Der Affinitäts-Score selektiert entlang der X-Achse, der CATE entlang der Y-Achse.

1.1.2 Umfeld

Einsatzfeld	Direktwerbeaktionen über die Kanäle Brief und E-Mail für verschiedene Produkte, u. a. Privathaftpflicht (PH) und Verkehrsrechtsschutz (VRS).
Erzeugung der Scores	Die kausalen Scores werden wöchentlich in Batch-Jobs auf dem Kundenbestand erzeugt.
Nutzer / Übergabe	Die Scores werden an die Marketing-Abteilung übergeben und in der Gruppe MA41 zur Sortierung und Auswahl der Kunden für die jeweilige Kampagne verwendet.

Veränderungszyklen	Wöchentliche Neuberechnung der Scores; Kampagnen werden fallweise durch das Marketing aufgesetzt. Modell-Retrainings erfolgen anlassbezogen (siehe Abschnitt 1.3).
---------------------------	--

1.2 Definition der zu messenden Größen

1.2.1 Wiederverwendung bestehender Messkonzepte

Ein geeignetes bestehendes Messkonzept lag nicht vor; das hier beschriebene Konzept wurde neu erstellt. Es ist jedoch **produktübergreifend wiederverwendbar** und wird je Produkt (PH, VRS, weitere) instanziiert — die Einzelmessungen (Abschnitt 3) dokumentieren die jeweilige Instanziierung.

1.2.2 Nutzenhebel, Formel und Baseline

Der Nutzenhebel ist die zusätzliche Wirkung, die allein aus der geänderten Kundenselektion bei *fester* Kampagnengröße entsteht. Als **Baseline** dient die frühere Selektion nach Affinitäts-Score. Für beide Selektionsmengen wird der geschätzte CATE *desselben* kausalen Modells aufsummiert; die Differenz ist der Nutzenhebel:

$$U = \sum_{i \in S_{\text{kausal}}} (x_i) - \sum_{i \in S_{\text{affinität}}} (x_i)$$

Äquivalent als Summe über die Mengendifferenz (die Schnittmenge kürzt sich):

$$U = \sum_{i \in (S_{\text{kausal}} \setminus S_{\text{affinität}})} (x_i) - \sum_{i \in (S_{\text{affinität}} \setminus S_{\text{kausal}})} (x_i)$$

Einheit & Interpretation
U ist die erwartete Anzahl *zusätzlicher Abschlüsse*, die die kausale Selektion gegenüber der Affinitäts-Selektion bei identischer, fest vorgegebener Kampagnengröße liefert.




Abb. 2: Selektionsmengen. Der Nutzenhebel U entsteht durch Austausch der orangenen gegen die grüne exklusive Menge.

1.2.3 Überschneidung mit anderen Use Cases / Doppelzählung

Eine Doppelzählung des Nutzens mit anderen Marketingmaßnahmen wird ausgeschlossen, indem die im Rahmen einer Aktion behandelten Kunden für den Auswertungszeitraum der Aktion für andere Marketingmaßnahmen **gesperrt** werden. Dadurch ist der gemessene Effekt eindeutig der jeweiligen Aktion zuzuordnen und wird nicht zusätzlich einem anderen Use Case gutgeschrieben.

1.2.4 Definition der quantitativen Metriken

(a) KPIs mit Definition

KPI	Definition	Einheit
U (Nutzenhebel)	Differenz der aufsummierten CATEs zwischen kausaler und Affinitäts-Selektion	Zusätzliche Abschlüsse
Nutzen	Ökonomische Bewertung von U vor Handlungsfeldkosten (siehe h)	€

(b) Definierte Gruppen — wo und an wem wird gemessen?

Scoring-Universum	Der gesamte für die Aktion in Frage kommende Kundenbestand zum Scoring-Zeitpunkt (N Kunden).
S _{kausal}	Die Top-K Kunden nach — die tatsächlich beworbene Menge.
S _{affinität}	Die Top-K Kunden nach Affinitäts-Score $\hat{a}$ — die kontrafaktische Vergleichsmenge (frühere Logik).

(c) Messmethode

Die Messung ist eine **Simulation (modellbasierter kontrafaktischer Vergleich)**: Dasselbe validierte Modell bewertet beide Selektionsmengen; verglichen wird die Selektionslogik, nicht zwei verschiedene Modelle. Es wird pro Kampagne *kein* laufender randomisierter Holdout geführt — die kausale Gültigkeit stammt aus der Modellerstellung (Abschnitt 1.3).

Prozessfluss: Nutzenhebel-Berechnung pro Kampagne




Abb. 3: Prozessfluss — dieselben -Werte, zwei verschiedene Selektionen.

(d) Als konstant angenommene Größen (innerhalb einer Messung)

Kampagnengröße K	Für beide Selektionen identisch und fest vorgegeben.
Modell	Dasselbe Modell bewertet beide Mengen.
Kundenbestand-Snapshot	Ein fixierter Bestand zum Scoring-Zeitpunkt.
Produkt, Kanal, Werbemittel	Identisch zwischen den Selektionslogiken.
Ø Deckungsbeitrag je Abschluss	Innerhalb einer Messung konstant (zwischen Messungen variabel, siehe h).

(e) Nicht direkt messbare Parameter und Annahmen

Annahme	Begründung	Vor-/Nachteil
liefert ein konsistentes Ranking der wahren CATES	Wird nicht pro Kampagne, sondern bei der Modellerstellung über Calibration-Plots auf randomisierten Daten geprüft.	+ theoretisch fundiert; Gültigkeit hängt an Kalibrierung und Aktualität des Modells.
Keine Interferenz zwischen Kunden (SUTVA)	Die Reaktion eines Kunden hängt nur von seiner eigenen Bewerbung ab.	+ ermöglicht additive Aufsummierung; bei Haushalts-/Netzwerkeffekten leicht verzerrt.
Affinitäts-Baseline bildet das reale frühere Vorgehen ab	Der historische Affinitäts-Score ist die dokumentierte Vorgänger-Selektion.	+ fairer Vergleichsmaßstab; falls das frühere Vorgehen manuelle Zusatzregeln enthielt, ist die Baseline eine Vereinfachung.
Deckungsbeitrag je Abschluss	Wird als Parameter zum Messzeitpunkt eingesetzt, nicht modelliert.	+ transparent; erwarteter, kein realisierter DB.

(f) Zuordnung des Effekts zur DA-Aktivität

Da K, Produkt, Kanal und Werbemittel zwischen beiden Selektionen konstant gehalten werden, unterscheidet sich *ausschließlich* die Selektionslogik. Der gemessene Effekt U ist damit vollständig der DA-Aktivität (Umstellung Affinität Kausalmodell) zuzuordnen und nicht durch Kampagnen-Rahmenbedingungen verzerrt.

(g) Abdeckung aller relevanten Nutzeneffekte

U erfasst den inkrementellen Abschlusseffekt der besseren Selektion — den Kern-Wirkhebel des Use Cases. Nicht erfasst sind Zweitrundeneffekte (z. B. Cross-/Up-Selling-Folgen, langfristige Kundenbindung, vermiedene Negativreaktionen bei Sleeping Dogs über die Abschlussmetrik hinaus). Diese Grenzen werden bewusst in Kauf genommen; U ist damit eine *konservative* Nutzengröße.

(h) Ökonomischer Nutzen inkl. Berechnung

Aus dem Nutzenhebel U wird der ökonomische Nutzen in drei Schritten hergeleitet:

Schritt 1 — Bruttoertrag des Nutzenhebels. Jeder zusätzliche Abschluss trägt im Mittel den Deckungsbeitrag DB (produktspezifisch):

$$\text{Bruttoertrag} = U \times \text{DB}$$

Schritt 2 — Unmittelbar dem Use Case zuzuordnende Kosten. Da die Kampagnengröße K für S_{kausal} und $S_{\text{affinität}}$ identisch fest ist, entstehen in beiden Fällen dieselben Versand- und Beauftragungskosten. Die DA-Aktivität ändert nicht die Anzahl der Maßnahmen, sondern nur deren Adressaten. Diese Kosten heben sich daher im Differenzmaß U auf:

$$C_{\text{Use Case}(S_{\text{kausal}})} - C_{\text{Use Case}(S_{\text{affinität}})} = 0$$

Der Nutzen (brutto, vor Handlungsfeldkosten) ist damit:

$$\text{Nutzen} = U \times \text{DB}$$

Konsistenz der Messung

Bei gegebenem Modell, festem Kundenbestand-Snapshot und festem K ist U **deterministisch und exakt reproduzierbar** — Mehrfachmessungen desselben Stands liefern identische Werte. Unterschiede *zwischen* Messungen (verschiedene Kampagnen/Zeitpunkte) sind auf Modell-Retrainings und Bestandsänderungen zurückzuführen, nicht auf Messrauschen; sie werden durch die kampagnenweise Einzelausweisung (Abschnitt 1.4) sauber getrennt.

(j) Erster Messtermin

Erstmessung	Oktober 2024, Produkt Privathaftpflicht (PH).
Weitere Instanziierungen	Werden je Kampagne/Produkt in Abschnitt 3 dokumentiert.

1.3 Experimentaufbau für die Datensammlung

Es sind zwei Ebenen zu unterscheiden:

1.3.1 Ebene 1 — Modellerstellung (randomisierte Experimente)

Die kausalen Modelle wurden auf Basis **randomisierter Experimente** (Treatment-/Kontroll-Split) erstellt, um den Uplift bestmöglich vorherzusagen. Eine gute **Kalibrierung** ist hier entscheidend, da die spätere Nutzenmessung auf der Verlässlichkeit des CATE-Rankings beruht. Die Validierung erfolgt über DRTester, Qini-Kurven und Calibration-Plots im Rahmen der Modellentwicklung.

1.3.2 Ebene 2 — Nutzenmessung (Simulation)

Die Nutzen- bzw. Mehrwerte je Kampagne werden anschließend **rein durch Simulation** bestimmt: Vergleich der Auswahl nach Kausal-Score gegen die frühere Auswahl nach Affinitäts-Score, bewertet mit demselben Modell (Abschnitt 1.2.4 c). Ein laufender randomisierter Holdout pro Kampagne ist nicht erforderlich, wird aber dennoch gemacht, um über die Zeit hinweg beurteilen zu können, ob alles noch richtig läuft.

1.3.3 Aktuelle vs. historische Daten

Das Modell stützt sich auf *historische* randomisierte Experimentendaten. Die Nutzenmessung selbst nutzt den *aktuellen* Kundenbestand-Snapshot der jeweiligen Kampagne. Ein Re-Training des Modells auf neueren Experimentendaten erfolgt anlassbezogen; der jeweils verwendete Modellstand wird in der Einzelmessung dokumentiert.

1.4 Datenauswertung und Entscheidungen

Je Kampagne wird der endgültige Messwert wie folgt bestimmt:

- **Scoring:** Anwendung des kausalen Modells auf den Kundenbestand (x_i) je Kunde.
- **Selektionen bilden:** S_{kausal} (Top-K nach $\hat{\mu}$) und $S_{\text{affinität}}$ (Top-K nach $\hat{a}$) — Letztere per Sortierung, ohne eigenen Modell-Lauf.
- **CATE summieren:** über beide Mengen.
- **Nutzenhebel:** U als Differenz.

Monetarisierung: Nutzen = $U \times \text{DB}$, mit den zum Messzeitpunkt gültigen Parametern.

Entscheidungsregel

Der Mehrwert wird **je Kampagne einzeln** ausgewiesen. Es findet *keine* Mittelung über Kampagnen statt; jede Instanziierung steht für sich.

Rechenbeispiel (illustrativ)

	S_{kausal} (Top 100k CATE)	$S_{\text{affinität}}$ (Top 100k Affinität)
(x_i)	4.820 Zusatzabschlüsse	2.130 Zusatzabschlüsse
U	4.820 2.130 = 2.690 zusätzliche Abschlüsse	

Bei einem angenommenen Deckungsbeitrag DB ergäbe sich ein Nutzen von $2.690 \times \text{DB}$ und nach Abzug von C_{HF} der Mehrwert. (Die konkreten €-Werte werden erst in der Einzelmessung eingesetzt.)

2 Verweis auf die Referenzimplementierung

Pfade:

- **Nachbestimmung der CATEs zum Zeitpunkt der Aktion mittels historisierter Daten:**
Domino-Projekt HF1_MA mnt/Production/PH_production/Mehrwert/2303v2_2307v3_PH1_Brief_Production_withDT_for Mehrwert_2410.ipynb
- **Bestimmung des Nutzens:**
Domino-Projekt HF1_MA mnt/Production/PH_production/Mehrwert/Mehrwert_2410.ipynb

3 Durchführung der Einzelmessungen

Jede Messung wird als eigene Instanziierung auf einer Einzelseite (alternativ in Excel, falls für die Zusammenarbeit mit anderen Gruppen praktischer) dokumentiert. Sie umfasst alle Messgrößen, die verwendeten Parameter sowie Auffälligkeiten/Sonderfälle. Vorlage:

Feld	Wert
Kampagne / Aktion	[Bezeichnung]
Produkt	[z. B. PH / VRS]
Kanal	[Brief / E-Mail]
Messdatum / Messzeitpunkt	[Datum]
Kampagnengröße K	[Anzahl Maßnahmen]
über S_{kausal}	[Wert]
über $S_{\text{affinität}}$	[Wert]
U (Zusatzabschlüsse)	[Wert]
Ø Deckungsbeitrag je Abschluss (DB)	[€ zum Messzeitpunkt]
Nutzen (€) = U × DB	[Wert]