KAUSALE WIRKUNGSANALYSE · LEAD-AUSSPIELUNG HUS/RS

Die Lead-Ausspielung wirkt. Wer stärker reagiert, ist nicht lernbar.

Warum der Gesamteffekt (ATE) klar belegt ist – heterogene Effekte je Teilgruppe (CATE) aber im statistischen Rauschen verschwinden.

+0,9 pp

Gesamteffekt auf die Abschlussquote – klar belegt ($z \approx 4$)

≈ 1 pp

typische Größenordnung der Unterschiede zwischen Segmenten

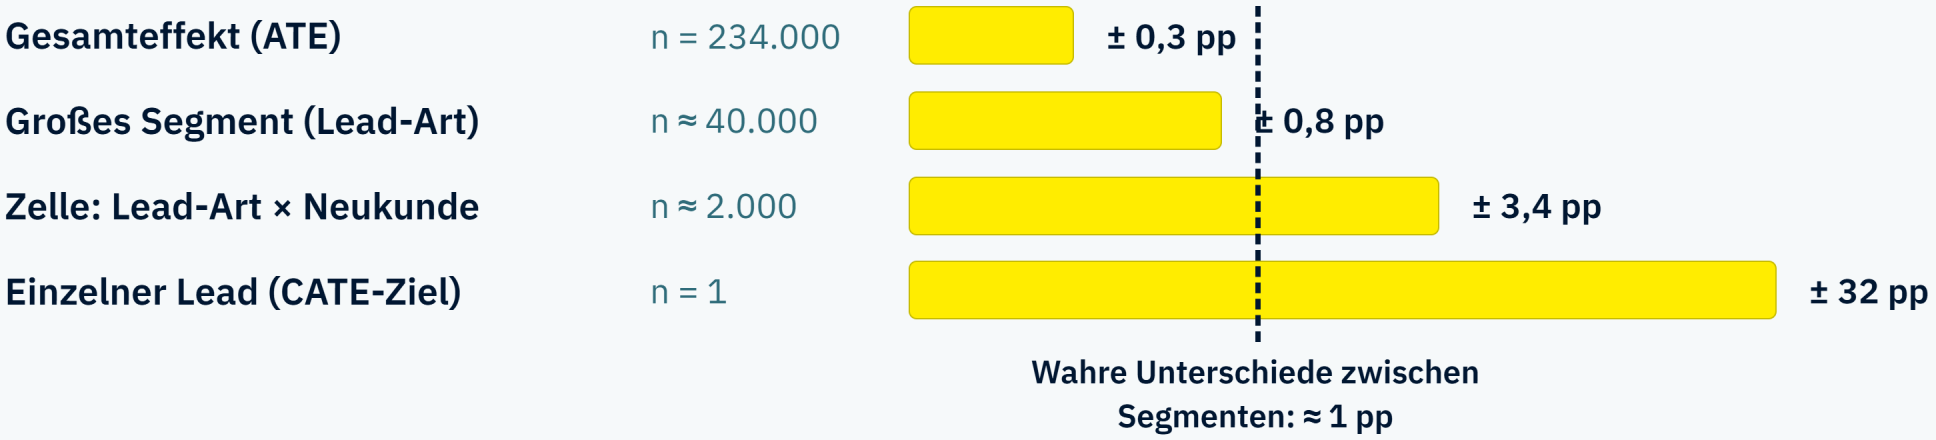
± 32 pp

statistisches Rauschen je einzelnem Lead (binäres Outcome)

Evaluationsbasis: n = 233.781 · Abschlussquote ≈ 13 % · randomisierte Ausspielung 75/25

Jede Effektmessung hat einen physikalischen Mindestfehler

Bei binärem Outcome (Abschluss ja/nein) gilt SE ≈ √(2 · p(1−p) / n) – der Fehler sinkt nur mit der Fallzahl, nicht mit besseren Modellen.

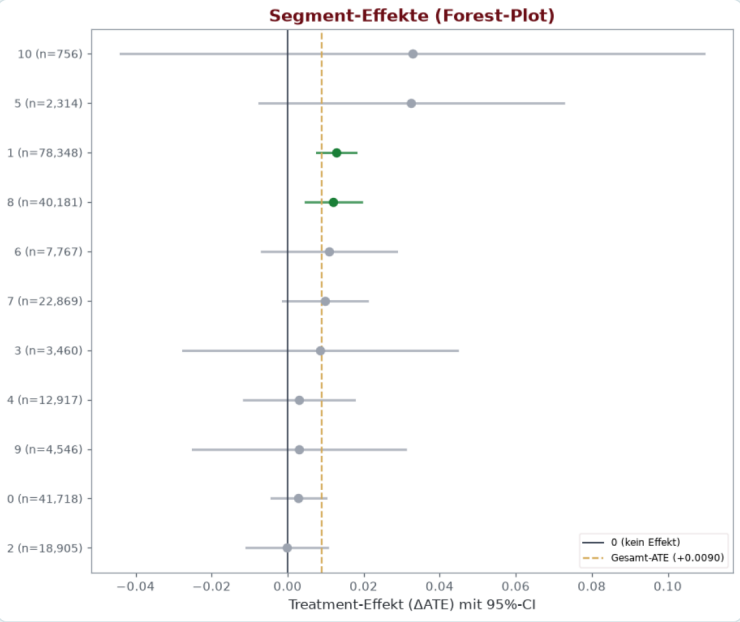


Balkenlänge: 95-%-Halbbreite des Messfehlers (1,96 · SE) bei 75/25-Zuteilung und p ≈ 13 %; Einzel-Lead: ± 1 Standardabweichung des Outcomes. Logarithmische Skala – jede Stufe nach rechts entspricht Faktor 10. „Neukunde“ = FEATURES_FEHLEN_FLG: Leads ohne Bestandsmerkmale.

Der Gesamteffekt (+0,9 pp) ist rund 4-mal größer als sein Messfehler → sicher nachweisbar.

Die Unterschiede zwischen Teilgruppen (≈ 1 pp) sind kleiner als der Fehler, mit dem man sie messen kann → jedes Verfahren sieht dort überwiegend Zufall.

Das Modell sieht fast nur Fehler – es bleiben zwei Auswege, beide schlecht



Lauf 3, echte Daten (Segmente = Lead-Arten): Alle Intervalle überlappen den Gesamt-ATE und einander.

Weg 1: Rauschen lernen („Winner's Curse")

Jeder Baum-Split ist selbst eine Messung – mit demselben Fehler wie links. Das Maximum über hunderte Split-Kandidaten pickt systematisch die größten Zufallsausreißer, nicht die echten Effekte.

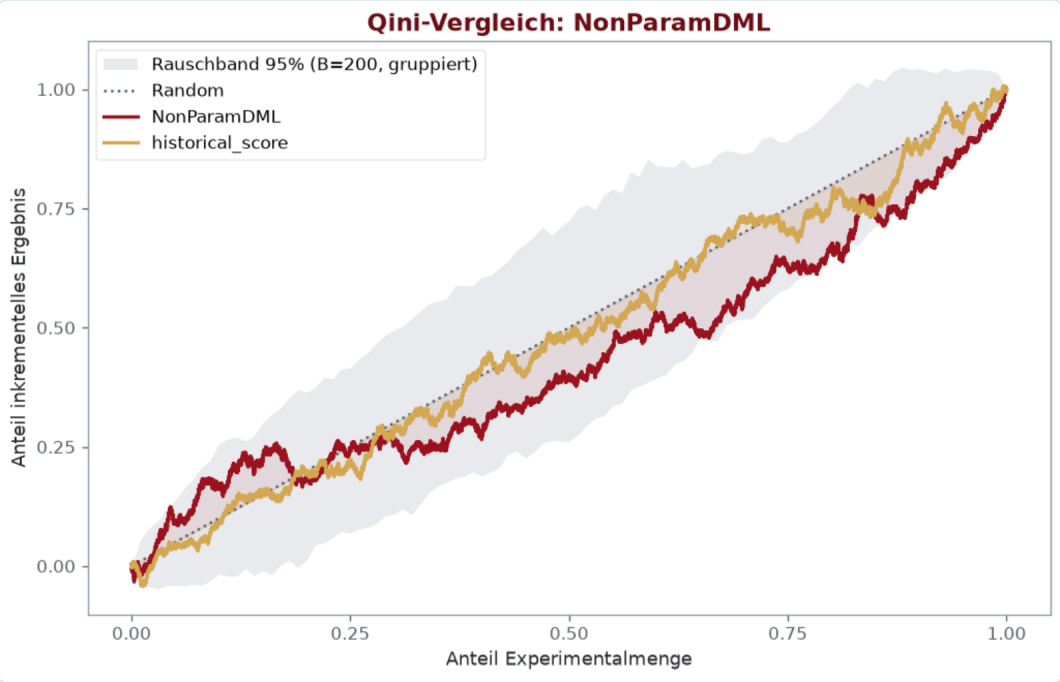
Weg 2: Nichts lernen

Regularisierung verweigert Splits ohne belastbaren Gewinn – die Vorhersage kollabiert Richtung Gesamteffekt. Das Modell „wird nicht besser", weil es ehrlich ist.

Harte Obergrenze

Selbst ein perfektes Verfahren übernimmt nur $Signal^2 / (Signal^2 + Fehler^2)$ des Gesehenen: ≈ 6–20 % je Segment, ≈ 0,1 % je Lead. Faustregel: Überlappen sich die Fehlerbalken, ist die Reihenfolge der Segmente nicht lernbar.

Der Praxis-Befund: alle Läufe im Zufallsband



Lauf 3: Champion-Modell und historischer Score verlaufen vollständig im grauen Rauschband (200 Permutationen, gruppenweise) – ununterscheidbar von einem Score, der nichts weiß.

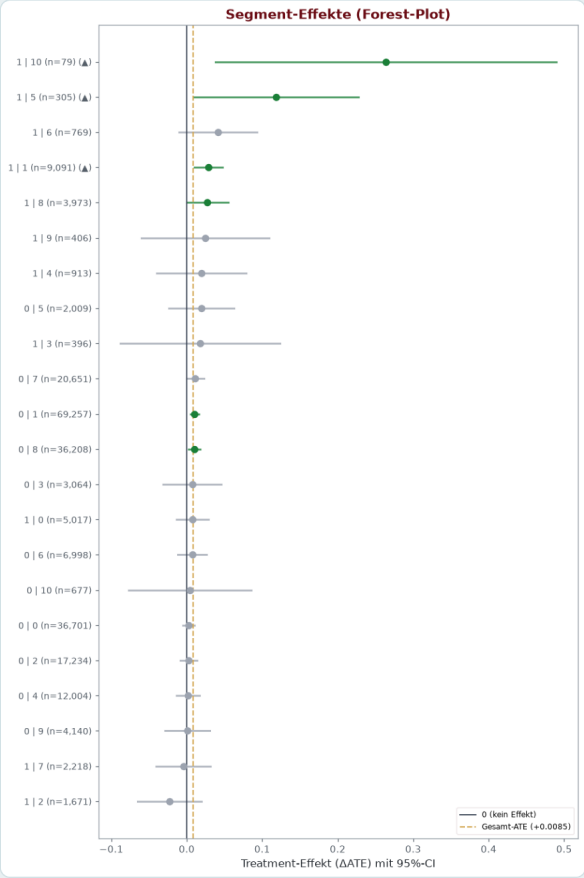
Lauf	Features	Champion-Qini
Report 1	727	+0,0007
Report 2	727	+0,0001
Report 3	3	−0,0004

Qini-Zufallsband (2σ): ± 0,0008 · Segment-Benchmark: −0,0003 / −0,0006 – ebenfalls im Band

Gleiche Daten, gleiches Experiment, jeweils volle Pipeline inkl. Hyperparameter-Suche – die Spannweite der drei Werte ist Seed-Lotterie, kein Lernfortschritt.

Auch mit nur 3 Features ändert sich nichts – und der Q-Test verwirft Homogenität in keinem Lauf ($\tau^2 = 0$): Der Segment-Benchmark kollabiert auf den Gesamt-ATE.

Der einzige belastbare Kandidat: Neukunden



Lauf 2, Segmente = Neukunde | Lead-Art („1 | …“ = Neukunde: FEATURES_FEHLEN_FLG, keine Bestandsmerkmale vorhanden).

Alle drei auffälligen Zellen sind Neukunden-Zellen

1 | 1 (n = 9.091): +2,9 pp, z = 2,97 · außerdem 1 | 5 und 1 | 10 – jeweils Tendenz (▲), nach Multiplizitätskorrektur (Benjamini-Hochberg) einzeln nicht belegt.

Gepoolt ein auffälliges Muster

Neukunden zusammengefasst: z ≈ 2,6. Die Segmentwahl war allerdings explorativ und nicht vorab festgelegt – nach den üblichen Maßstäben ist das ein Hinweis, kein Beleg.

Bestand: eng am Gesamteffekt

Die großen Bestandszellen (0 | …) liegen dicht am Gesamt-ATE. Keine einzige Zelle ist „unwirksam belegt“ – eine Abschaltung einzelner Lead-Arten lässt sich aus diesen Daten nicht rechtfertigen.

Zusammenfassung

Was wir gesehen haben

- Die Ausspielung erhöht die Abschlussquote um +0,9 pp ($z \approx 4$), stabil über alle drei Läufe.
- Kein Modell erreicht einen Qini außerhalb des Zufallsbands von ±0,0008, auch nicht mit reduziertem Feature-Satz; der Q-Test findet in keinem Lauf belastbare Heterogenität ($\tau^2 = 0$).
- Die Neukunden-Zellen liegen durchgehend über dem Gesamteffekt – einzeln nicht signifikant, zusammengefasst $z \approx 2{,}6$.
- Zwei Lead-Arten (0 und 2) liegen nahe null; Lead-Art 0 verfehlt die Signifikanz gegen den Rest knapp ($p = 0{,}09$ unkorrigiert, 0,34 nach Benjamini-Hochberg).

Was sich daraus ableiten lässt

- Das Niveau des Effekts ist belastbar beziffert und trägt die Ausspielung insgesamt.
- Bei Neukunden deutet sich eine stärkere Wirkung an – nach heutigem Stand ein Hinweis, kein Beleg.
- Eine modellbasierte Reihenfolge der Leads bringt nach aktuellem Stand keinen messbaren Mehrwert gegenüber der bisherigen Ausspielung.

Was sich daraus nicht ableiten lässt

- Mehr als Hinweise aus den Segmentvergleichen: Die betrachteten Segmentierungen wurden im Nachhinein gewählt, nicht vorab festgelegt – auffällige einzelne Zellen sind dadurch zusätzlich vorsichtig zu lesen.
- Dass einzelne Lead-Arten nicht wirken: Bei überall gleichem Effekt wären rechnerisch etwa zwei scheinbar negative Lead-Arten zu erwarten (mindestens eine mit 87 % Wahrscheinlichkeit) – die beiden auffälligen Segmente passen in dieses Muster.
- Ein Abschalten einzelner Lead-Arten. Wer depriorisiert, trifft eine Geschäftsentscheidung; aus den Daten begründen lässt sie sich derzeit nicht.