KAUSALE WIRKUNGSANALYSE · LEAD-AUSSPIELUNG HUS/RS

Die Lead-Ausspielung wirkt. Wer stärker reagiert, ist nicht lernbar.

Warum der Gesamteffekt (ATE) klar belegt ist – heterogene Effekte je Teilgruppe (CATE) aber im statistischen Rauschen verschwinden.

+0,9 pp

Gesamteffekt auf die Abschlussquote – klar belegt (z ≈ 4)

≈ 1 pp

typische Größenordnung der Unterschiede zwischen Segmenten

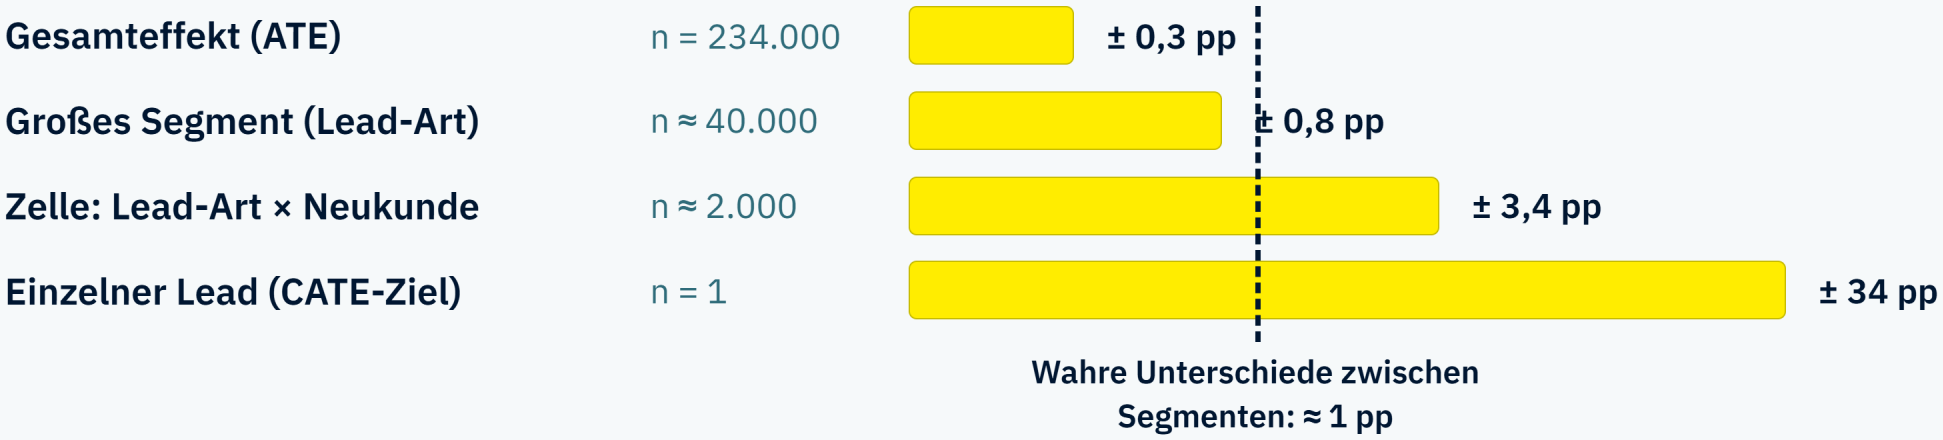
± 34 pp

statistisches Rauschen je einzelnem Lead (binäres Outcome)

Evaluationsbasis: n = 233.781 · Abschlussquote ≈ 13 % · randomisierte Ausspielung 75/25

Jede Effektmessung hat einen physikalischen Mindestfehler

Bei binärem Outcome (Abschluss ja/nein) gilt SE ≈ √(2 · p(1−p) / n) – der Fehler sinkt nur mit der Fallzahl, nicht mit besseren Modellen.

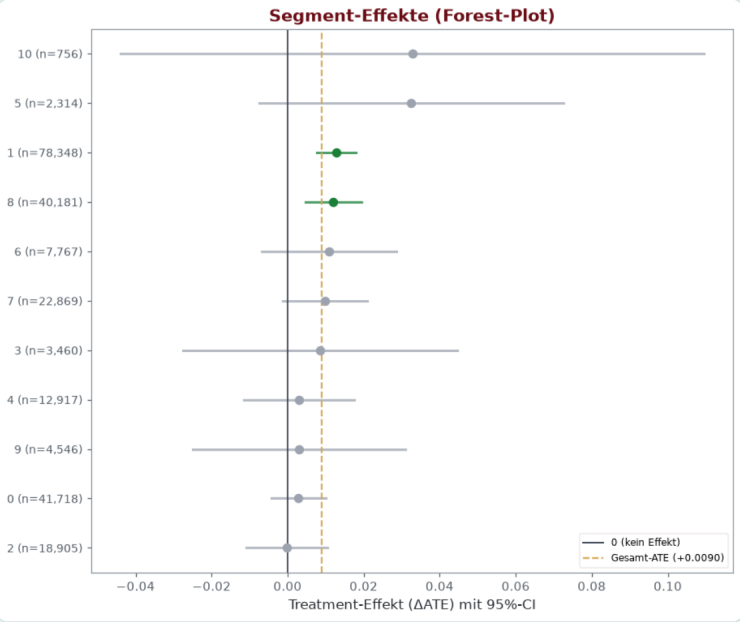


Balkenlänge: 95-%-Halbbreite des Messfehlers (1,96 · SE) bei 75/25-Zuteilung und p ≈ 13 %; Einzel-Lead: ± 1 Standardabweichung des Outcomes. Logarithmische Skala – jede Stufe nach rechts entspricht Faktor 10. „Neukunde“ = FEATURES_FEHLEN_FLG: Leads ohne Bestandsmerkmale.

Der Gesamteffekt (+0,9 pp) ist rund 4-mal größer als sein Messfehler → sicher nachweisbar.

Die Unterschiede zwischen Teilgruppen (≈ 1 pp) sind kleiner als der Fehler, mit dem man sie messen kann → jedes Verfahren sieht dort überwiegend Zufall.

Das Modell sieht fast nur Fehler – es bleiben zwei Auswege, beide schlecht



Lauf 3, echte Daten (Segmente = Lead-Arten): Alle Intervalle überlappen den Gesamt-ATE und einander.

Weg 1: Rauschen lernen („Winner's Curse")

Jeder Baum-Split ist selbst eine Messung – mit demselben Fehler wie links. Das Maximum über hunderte Split-Kandidaten pickt systematisch die größten Zufallsausreißer, nicht die echten Effekte.

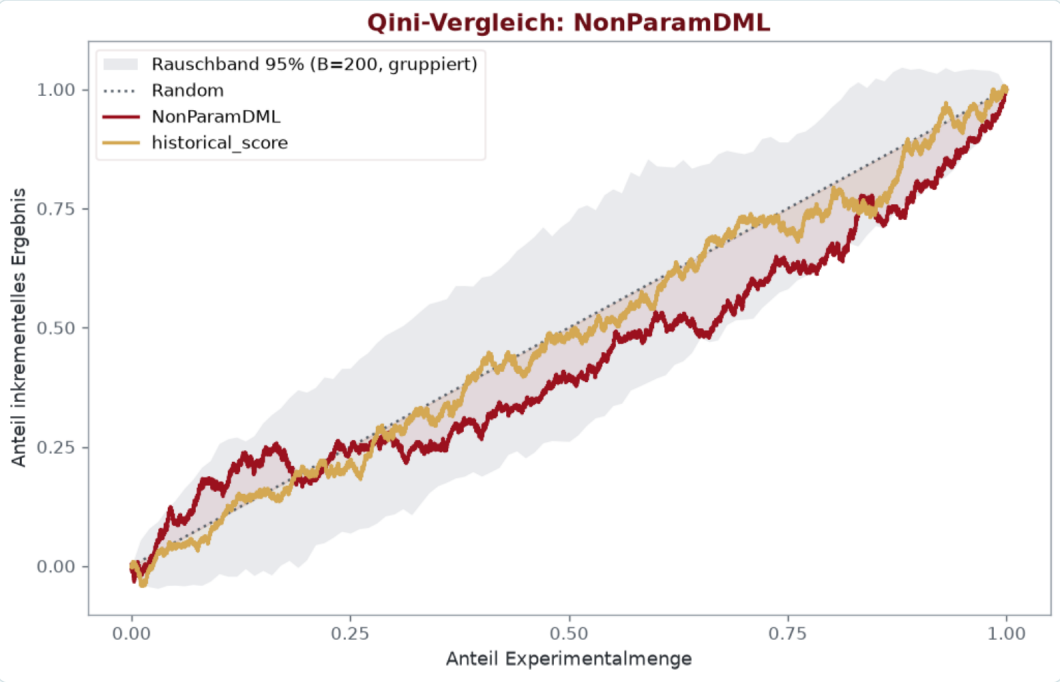
Weg 2: Nichts lernen

Regularisierung verweigert Splits ohne belastbaren Gewinn – die Vorhersage kollabiert Richtung Gesamteffekt. Das Modell „wird nicht besser", weil es ehrlich ist.

Harte Obergrenze

Selbst ein perfektes Verfahren übernimmt nur $Signal^2 / (Signal^2 + Fehler^2)$ des Gesehenen: ≈ 6–20 % je Segment, ≈ 0,1 % je Lead. Faustregel: Überlappen sich die Fehlerbalken, ist die Reihenfolge der Segmente nicht lernbar.

Der Praxis-Befund: alle Läufe im Zufallsband



Lauf 3: Champion-Modell und historischer Score verlaufen vollständig im grauen Rauschband (200 Permutationen, gruppenweise) – ununterscheidbar von einem Score, der nichts weiß.

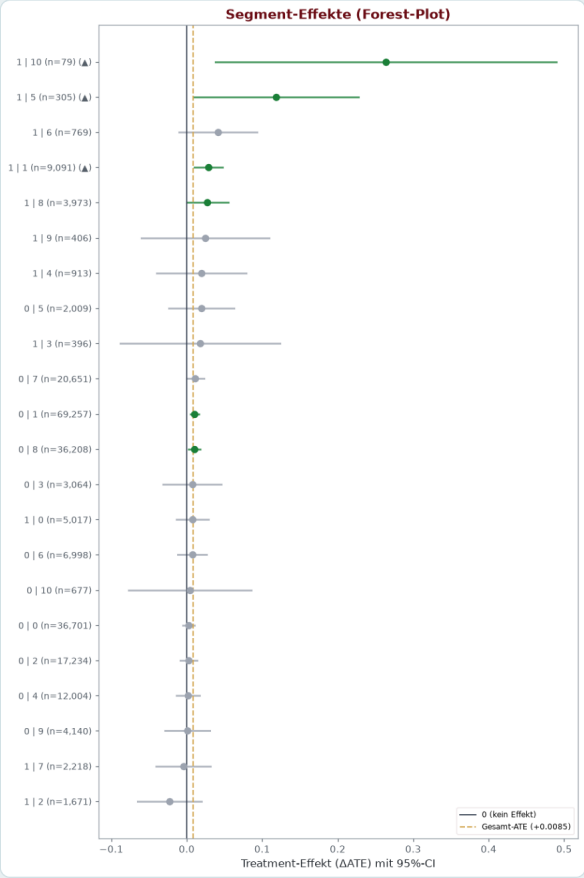
Lauf	Features	Champion-Qini
Report 1	727	+0,0007
Report 2	727	+0,0001
Report 3	3	−0,0004

Qini-Zufallsband (2σ): ± 0,0008 · Segment-Benchmark: −0,0003 / −0,0006 – ebenfalls im Band

Gleiche Daten, gleiches Experiment, jeweils volle Pipeline inkl. Hyperparameter-Suche – die Spannweite der drei Werte ist Seed-Lotterie, kein Lernfortschritt.

Auch mit nur 3 Features ändert sich nichts – und der Q-Test verwirft Homogenität in keinem Lauf ($\tau^2 = 0$): Der Segment-Benchmark kollabiert auf den Gesamt-ATE.

Der einzige belastbare Kandidat: Neukunden



Lauf 2, Segmente = Neukunde | Lead-Art („1 | …“ = Neukunde: FEATURES_FEHLEN_FLG, keine Bestandsmerkmale vorhanden).

Alle drei auffälligen Zellen sind Neukunden-Zellen

1 | 1 (n = 9.091): +2,9 pp, z = 2,97 · außerdem 1 | 5 und 1 | 10 – jeweils Tendenz (▲), nach Multiplizitätskorrektur (Benjamini-Hochberg) einzeln nicht belegt.

Gepoolt ein auffälliges Muster

Neukunden zusammengefasst: z ≈ 2,6. Die Segmentwahl war allerdings explorativ und nicht vorab festgelegt – nach den üblichen Maßstäben ist das ein Hinweis, kein Beleg.

Bestand: eng am Gesamteffekt

Die großen Bestandszellen (0 | …) liegen dicht am Gesamt-ATE. Keine einzige Zelle ist „unwirksam belegt“ – eine Abschaltung einzelner Lead-Arten lässt sich aus diesen Daten nicht rechtfertigen.

Zusammenfassung

Was wir gesehen haben

- Die Ausspielung erhöht die Abschlussquote um +0,9 pp ($z \approx 4$), stabil über alle drei Läufe.
- Kein Modell erreicht einen Qini außerhalb des Zufallsbands von ±0,0008, auch nicht mit reduziertem Feature-Satz; der Q-Test findet in keinem Lauf belastbare Heterogenität ($\tau^2 = 0$).
- Die Neukunden-Zellen liegen durchgehend über dem Gesamteffekt – einzeln nicht signifikant, zusammengefasst $z \approx 2{,}6$.
- Zwei Lead-Arten (0 und 2) liegen nahe null; Lead-Art 0 verfehlt die Signifikanz gegen den Rest knapp ($p = 0{,}09$ unkorrigiert, 0,34 nach Benjamini-Hochberg).

Was sich daraus ableiten lässt

- Das Niveau des Effekts ist belastbar beziffert und trägt die Ausspielung insgesamt.
- Bei Neukunden deutet sich eine stärkere Wirkung an – nach heutigem Stand ein Hinweis, kein Beleg.
- Eine modellbasierte Reihenfolge der Leads bringt nach aktuellem Stand keinen messbaren Mehrwert gegenüber der bisherigen Ausspielung.

Was sich daraus nicht ableiten lässt

- Mehr als Hinweise aus den Segmentvergleichen: Die betrachteten Segmentierungen wurden im Nachhinein gewählt, nicht vorab festgelegt – auffällige einzelne Zellen sind dadurch zusätzlich vorsichtig zu lesen.
- Dass einzelne Lead-Arten nicht wirken: Bei überall gleichem Effekt wären rechnerisch etwa zwei scheinbar negative Lead-Arten zu erwarten (mindestens eine mit 87 % Wahrscheinlichkeit) – die beiden auffälligen Segmente passen in dieses Muster.
- Ein Abschalten einzelner Lead-Arten. Wer depriorisiert, trifft eine Geschäftsentscheidung; aus den Daten begründen lässt sie sich derzeit nicht.

Anhang: Rechenwege (1/4) – Fehler, Vergleiche, Shrinkage

Messfehler je Ebene (Folie 2) – Beispiel Lead-Art mit N = 40.000

p(1−p) = 0,13 · 0,87 = 0,113 · bei 75/25: n_T = 30.000, n_C = 10.000

SE = √(0,113 · (1/30.000 + 1/10.000)) = √0,0000151 = 0,0039 → 95 %: 1,96 · 0,39 pp ≈ ± 0,8 pp

Gleiche Rechnung: N = 234.000 → ± 0,3 pp · N = 2.000 → ± 3,4 pp · einzelner Lead: ± 1 σ = √0,113 ≈ ± 34 pp

Vergleich zweier großer Segmente (Folie 3)

Fehler unabhängiger Messungen addieren sich quadratisch: SE(Δ) = √(0,39² + 0,39²) = 0,55 pp

Maximal plausibler Unterschied 1 pp → z = 1 / 0,55 ≈ 1,8 < 2 → selbst der Extremfall ist einzeln nicht belegbar

Übernehmbarer Anteil = Signal² / (Signal² + Fehler²) (Folie 3)

Signal = wahre Streuung zwischen Segmenten, hier als Obergrenze ≈ 1 pp (Q-Test: nicht von 0 unterscheidbar)

Zelle mit Fehler 2 pp: 1² / (1² + 2²) = 20 % → aus beobachteten +3 pp werden +0,6 pp · Fehler 4 pp: 1/17 ≈ 6 %

Einzelner Lead (Fehler 34 pp): 1 / (1 + 34²) ≈ 0,1 % – fast alles Beobachtete muss verworfen werden

Anhang: Rechenwege (2/4) – Neukunden, Zufallsmuster, Qini-Band

Neukunden gepoolt: z ≈ 2,6 (Folie 5)

Neukunden n ≈ 25.000 → SE = 0,78/√25.000 ≈ 0,49 pp · Rest n ≈ 209.000 → SE ≈ 0,17 pp

SE(Δ) = √(0,49² + 0,17²) ≈ 0,52 pp · beobachtet Δ ≈ +1,3 pp → z = 1,3 / 0,52 ≈ 2,6

„≈ 2 scheinbar negative Lead-Arten, 87 %“ (Folie 6)

Wahrer Effekt überall +0,9 pp. Je Lead-Art: P(Schätzer < 0) = Φ(−0,9 / SE)

Beispiel n ≈ 2.300: SE ≈ 1,6 pp → Φ(−0,55) ≈ 29 % · große Lead-Arten: nahe 0 %

Summe über alle 11 Lead-Arten ≈ 2 erwartete „negative“ · P(mindestens eine) = 1 − ∏(1 − p_i) ≈ 87 %

Qini-Zufallsband ± 0,0008 (Folie 4)

Echte Y und T bleiben fix; nur die Score-Zuordnung wird 200-mal zufällig permutiert (gruppenweise je Partner)

Je Permutation ein Qini-Koeffizient → Standardabweichung ≈ 0,0004 → Band = ± 2 σ ≈ ± 0,0008

Gemessen: +0,0007 / +0,0001 / −0,0004 – alle drei Läufe innerhalb des Bands

Anhang: Rechenwege (3/4) – Vergleich gegen den Rest und Multiplizitätskorrektur

Jedes Segment wird gegen den Rest getestet – nicht paarweise

Je Segment: Δ = ATE(Segment) − ATE(alle übrigen zusammen) · SE(Δ) = √(SE_Segment² + SE_Rest²)
Beispiel Lead-Art 0 (Lauf 3): n = 41.718 → SE ≈ 0,38 pp · Rest n ≈ 192.000 → SE ≈ 0,18 pp
Δ ≈ −0,70 pp · SE(Δ) = √(0,38² + 0,18²) ≈ 0,42 pp → z ≈ −1,7 → p (zweiseitig) ≈ 0,09

Multiplizitätskorrektur: Benjamini-Hochberg über alle Segment-Tests

11 Tests gleichzeitig: bei 5 % Fehlerquote je Test wären 1–2 Zufallstreffer normal
BH sortiert die p-Werte aufsteigend und reskaliert: p_adj = p · m / Rang (m = Anzahl Tests, dann monoton geglättet)
Beispiel Lead-Art 0: p = 0,092 auf Rang 3 von 11 → p_adj = 0,092 · 11/3 ≈ 0,34 → keine belegte Abweichung

Warum gegen den Rest statt aller Paarungen

Nur 11 Tests statt 55 Paarvergleichen → geringere Multiplizitätsstrafe · der Rest ist groß, sein Fehler klein
Und die Frage ist die geschäftlich relevante: Weicht dieses Segment vom übrigen Bestand ab?
Marker im Report: ▲/▼ erst bei p_adj < 0,05 · (▲)/(▼) = Tendenz (p unkorrigiert < 0,05)

Anhang: Rechenwege (4/4) – Der Q-Test auf Heterogenität

Die Frage: Streuen die Segment-Effekte stärker, als ihre Messfehler erklären?

$Q = \Sigma\, w_i \cdot (ATE_i - ATE_gepoolt)^2$ mit Gewichten $w_i = 1/SE_i^2$ – präzise gemessene Segmente zählen mehr

Wirkt überall derselbe Effekt, folgt Q einer χ^2-Verteilung mit $k-1$ Freiheitsgraden (k = Anzahl Segmente)

Erwartungswert unter Homogenität: $Q \approx k-1$ · erst ein deutlicher Überschuss belegt echte Unterschiede

Vom Q-Test zur Signal-Schätzung τ^2

Nur der Überschuss über die Freiheitsgrade wird dem Signal zugerechnet: $\tau^2 = (Q - (k-1)) / C$

Rechenbeispiel: $Q = 25$ bei $k-1 = 10 \rightarrow p \approx 0{,}005$, Überschuss 15 $\rightarrow \tau^2 > 0$, Heterogenität belegt

Unsere Läufe: $Q \leq k-1$, $p > 0{,}05 \rightarrow \tau^2 = 0$ – die sichtbare Streuung ist vollständig durch Messfehler erklärbar

Wozu das Ergebnis dient: Vorschalttest für den Benchmark

τ^2 ist die Schätzung des „Signal²“ aus Anhang 1/4 → Shrinkage-Faktor je Segment = $\tau^2 / (\tau^2 + SE^2)$

Erst wenn der Q-Test Homogenität verwirft ($p < 0{,}05$), fließen Segment-Abweichungen in den Benchmark-Score ein; sonst wird $\tau^2 = 0$ gesetzt und der Score kollabiert auf den Gesamt-ATE

Grund für den Vorschalttest: Auch bei perfekt homogenen Daten fiele ein roh geschätztes τ^2 in rund der Hälfte der Fälle zufällig größer als null aus