KAUSALE WIRKUNGSANALYSE · LEAD-AUSSPIELUNG HUS/RS

Die Lead-Ausspielung wirkt. Wer stärker reagiert, ist nicht lernbar.

Warum der Gesamteffekt (ATE) klar belegt ist – heterogene Effekte je Teilgruppe (CATE) aber im statistischen Rauschen verschwinden.

+0,9 pp

Gesamteffekt auf die Abschlussquote – klar belegt ($z \approx 4$)

≈ 1 pp

typische Größenordnung der Unterschiede zwischen Segmenten

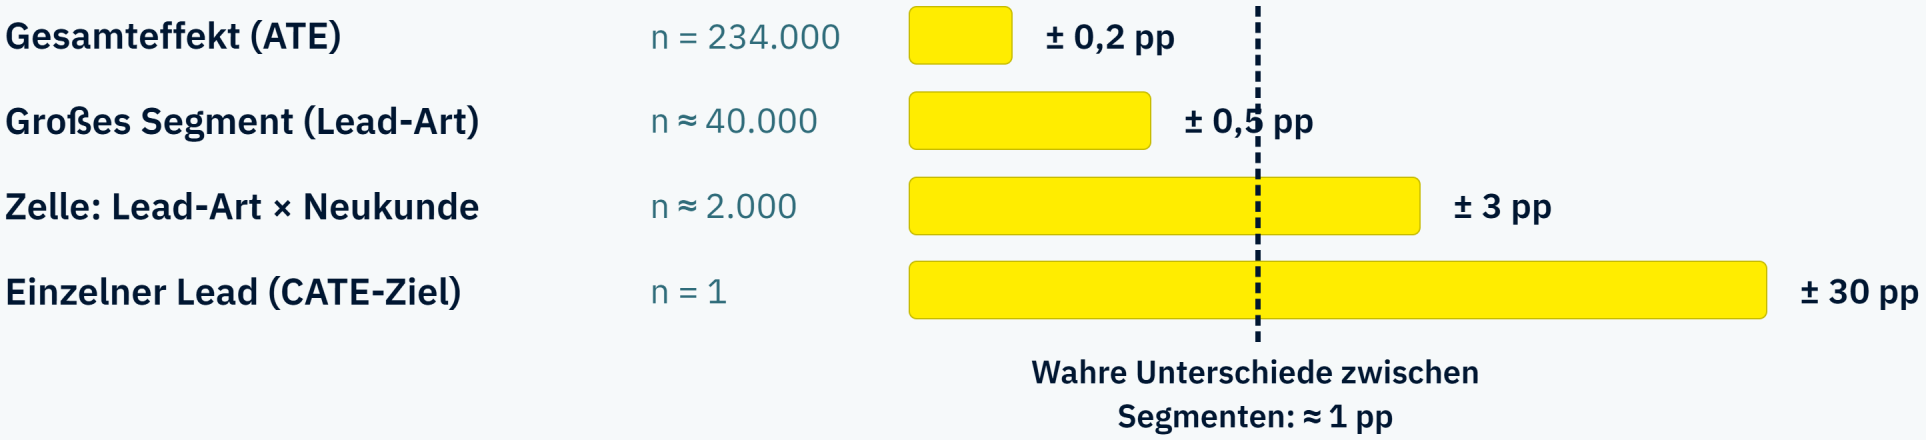
± 30 pp

statistisches Rauschen je einzelnem Lead (binäres Outcome)

Evaluationsbasis: n = 233.781 · Abschlussquote ≈ 13 % · randomisierte Ausspielung 75/25

Jede Effektmessung hat einen physikalischen Mindestfehler

Bei binärem Outcome (Abschluss ja/nein) gilt SE ≈ √(2 · p(1−p) / n) – der Fehler sinkt nur mit der Fallzahl, nicht mit besseren Modellen.

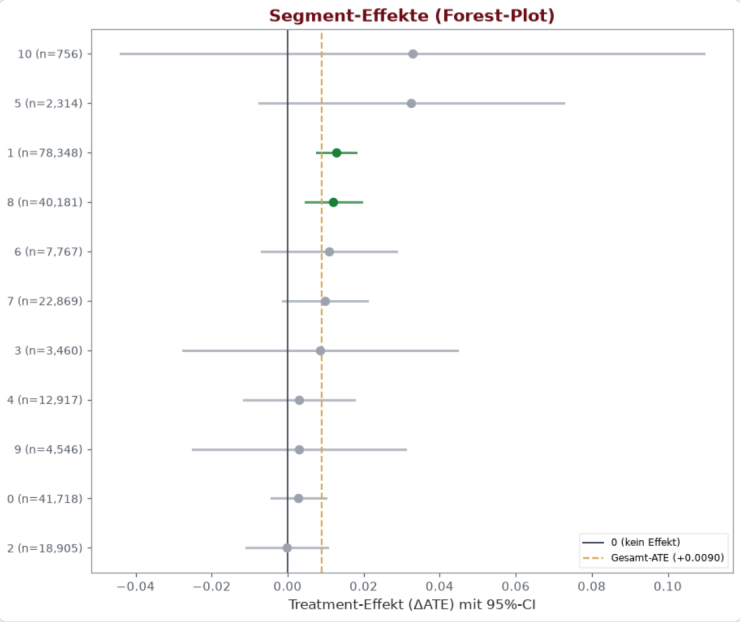


Balkenlänge: Messfehler (95-%-Halbbreite), logarithmische Skala – jede Stufe nach rechts entspricht Faktor 10. „Neukunde“ = FEATURES_FEHLEN_FLG: Leads ohne Bestandsmerkmale.

Der Gesamteffekt (+0,9 pp) ist rund 4-mal größer als sein Messfehler → sicher nachweisbar.

Die Unterschiede zwischen Teilgruppen (≈ 1 pp) sind kleiner als der Fehler, mit dem man sie messen kann → jedes Verfahren sieht dort überwiegend Zufall.

Das Modell sieht fast nur Fehler – es bleiben zwei Auswege, beide schlecht



Lauf 3, echte Daten (Segmente = Lead-Arten): Alle Intervalle überlappen den Gesamt-ATE und einander.

Weg 1: Rauschen lernen („Winner's Curse")

Jeder Baum-Split ist selbst eine Messung – mit demselben Fehler wie links. Das Maximum über hunderte Split-Kandidaten pickt systematisch die größten Zufallsausreißer, nicht die echten Effekte.

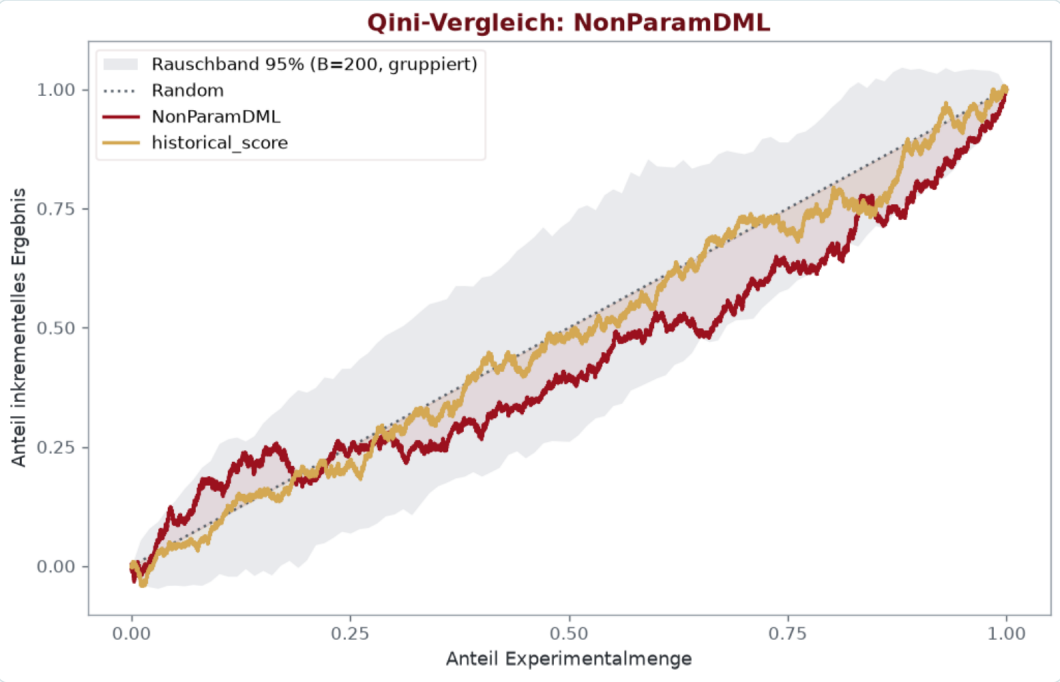
Weg 2: Nichts lernen

Regularisierung verweigert Splits ohne belastbaren Gewinn – die Vorhersage kollabiert Richtung Gesamteffekt. Das Modell „wird nicht besser", weil es ehrlich ist.

Harte Obergrenze

Selbst ein perfektes Verfahren übernimmt nur $Signal^2 / (Signal^2 + Fehler^2)$ des Gesehenen: ≈ 6–20 % je Segment, ≈ 0,1 % je Lead. Faustregel: Überlappen sich die Fehlerbalken, ist die Reihenfolge der Segmente nicht lernbar.

Der Praxis-Befund: alle Läufe im Zufallsband



Lauf 3: Champion-Modell und historischer Score verlaufen vollständig im grauen Rauschband (200 Permutationen, gruppenweise) – ununterscheidbar von einem Score, der nichts weiß.

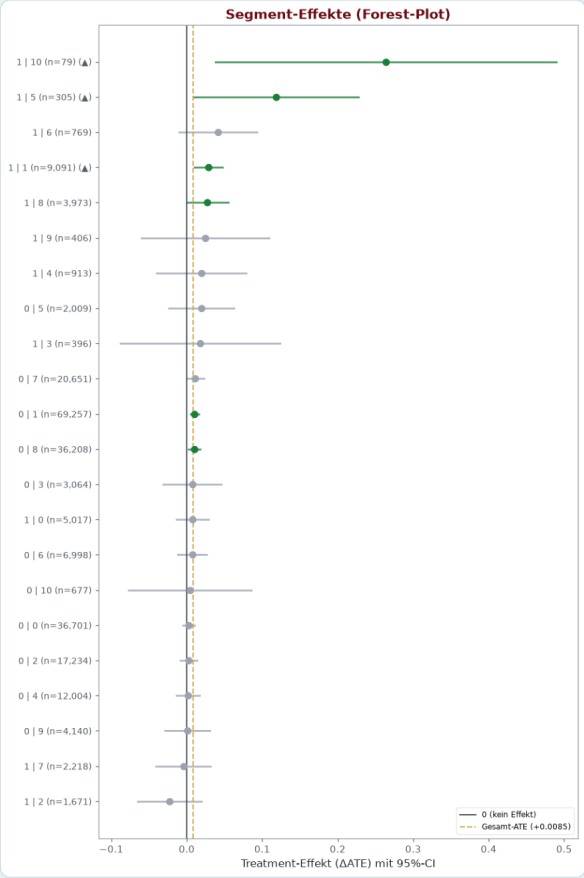
Lauf	Features	Champion-Qini
Report 1	727	+0,0007
Report 2	727	+0,0001
Report 3	3	−0,0004

Qini-Zufallsband (2σ): ± 0,0008 · Segment-Benchmark: −0,0003 / −0,0006 – ebenfalls im Band

Gleiche Daten, gleiches Experiment, jeweils volle Pipeline inkl. Hyperparameter-Suche – die Spannweite der drei Werte ist Seed-Lotterie, kein Lernfortschritt.

Auch mit nur 3 Features ändert sich nichts – und der Q-Test verwirft Homogenität in keinem Lauf ($\tau^2 = 0$): Der Segment-Benchmark kollabiert auf den Gesamt-ATE.

Der einzige belastbare Kandidat: Neukunden



Lauf 2, Segmente = Neukunde | Lead-Art („1 | …“ = Neukunde: FEATURES_FEHLEN_FLG, keine Bestandsmerkmale vorhanden).

Alle drei auffälligen Zellen sind Neukunden-Zellen

1 | 1 (n = 9.091): +2,9 pp, z = 2,97 · außerdem 1 | 5 und 1 | 10 – jeweils Tendenz (▲), nach Multiplizitätskorrektur (Benjamini-Hochberg) einzeln nicht belegt.

Gepoolt wird daraus ein Signal

Neukunden zusammengefasst: z ≈ 2,6. Als einzelne, vorregistrierte Hypothese im nächsten Ausspielungs-Zeitraum sauber belegbar – statt in 55 Paarvergleichen verdünnt zu werden.

Bestand: eng am Gesamteffekt

Die großen Bestandszellen (0 | …) liegen dicht am Gesamt-ATE. Keine einzige Zelle ist „unwirksam belegt“ – eine Abschaltung einzelner Lead-Arten lässt sich aus diesen Daten nicht rechtfertigen.

Konsequenzen: Design schlägt Modell

Scheinbare Muster sind erwartbar

Simulation mit unseren echten Fallzahlen, Effekt überall exakt +0,9 pp – also null Heterogenität:

- 87 % Wahrscheinlichkeit, dass ≥ 1 Lead-Art scheinbar negativ wirkt
- im Mittel ~3 Zellen, die „nur halb wirksam“ aussehen
- Segmentvergleiche ohne Signifikanztest erzeugen Heterogenität aus Rauschen

Was wirklich hilft

- Fehler halbieren = 4× Daten: Ausspielungs-Zeiträume poolen statt einzeln auswerten
- Kontrollgruppe kostet real Abschlüsse – 75/25 ist ein bewusster Trade-off; mehr Kontrolle nur gezielt und befristet, wo offene Hypothesen bestehen
- wenige vorregistrierte Hypothesen – v. a. Neukunden (FEATURES_FEHLEN_FLG) – statt 55 Paarvergleiche
- Depriorisierung als bewusste Ausspielregel (Policy) – nicht als Modell-Output

Ein homogener, belegter Effekt plus klare Ausspielregel schlägt ein Modell, das Rauschen sortiert.